

访问控制技术--层次聚类算法

【实验目的】

- 1、掌握数据分析的访问控制技术；
- 2、掌握层次聚类方法的基本原理及算法实现。

【实验人数】

每组 1 人

【系统环境】

Windows

【实验原理】

聚类分析或聚类是对一组对象进行分组的任务，使得同一组（称为聚类）中的对象（在某种意义上）与其他组（聚类）中的对象更相似（在某种意义上）。层次聚类（Hierarchical Clustering）是聚类算法的一种，通过计算不同类别数据点间的相似度来创建一棵有层次的嵌套聚类树。在聚类树中，不同类别的原始数据点是树的最低层，树的顶层是一个聚类的根节点。层次聚类算法相比划分聚类算法的优点之一是可以在不同的尺度上（层次）展示数据集的聚类情况。

凝聚层次聚类自底向上，先将每个对象作为簇，然后合并为越来越大的簇，直到某个终止条件被满足。即将每个对象归为一簇，共得到 N 个簇，每簇仅包含一个对象；计算簇与簇之间的距离，亦即它们所包含的对象之间的距离。

凝聚层次聚类算法中的一个关键步骤就是计算簇与簇之间的距离。簇与簇之间距离的基本计算方法有如下几种：

(1) 单链法 single-linkage: 分别求一个簇中每一个对象与另一个簇中的每一个对象的距离，然后取距离的最小值作为簇间距离，

$$d(c_i, c_j) = \min(\cup_{p \in c_i, q \in c_j} d(p, q));$$

(2) 全链法 complete-linkage: 别求一个簇中每一个对象与另一个簇中的每一个对象的距离，然后取距离的最大值作为簇间距离，

$$d(c_i, c_j) = \max(\cup_{p \in c_i, q \in c_j} d(p, q));$$

(3) 组平均法 average-linkage: 簇间距离等于两组对象之间的平均距离，

$$d(c_i, c_j) = \frac{\sum_{p \in c_i, p \in c_j} d(p, q)}{m_i m_j}。$$

【实验内容】

- 1、凝聚层次聚类算法实现（非聚类库函数调用），要求算法输入：随机生成聚类的 ≥ 20 个对象；算法输出：分类结果以及可视化的嵌套簇图，聚类过程中得到的最短距离值以及距离矩阵。考虑三种不同距离计算方法进行聚类；
- 2、使用 Sklearn 和 Scripy 实现层次聚类。

【思考问题】

- 3、凝聚层次聚类的优缺点是什么？（500+字）
- 4、给出另一种聚类方法，并简述其基本思想。（500+字）

【实验报告要求】

- 1、详细描述算法的基本原理，算法流程图；
- 2、算法核心函数给出必要的备注和解释说明；
- 3、详细记录实验结果数据，并对所得到的数据分析原因；
- 4、心得体会。

【参考资料】

<https://blog.csdn.net/liujh845633242/article/details/103679724?spm=1001.2014.3001.5506>

<https://www.cnblogs.com/JetpropelledSnake/p/14513657.html>